kaggle

Sign up Login

What's cooking Homework

The Home of Data Science

COMPETITIONS ▪ CUSTOMER SOLUTIONS ▪ JOBS BOARD

Get started »

DM14301033

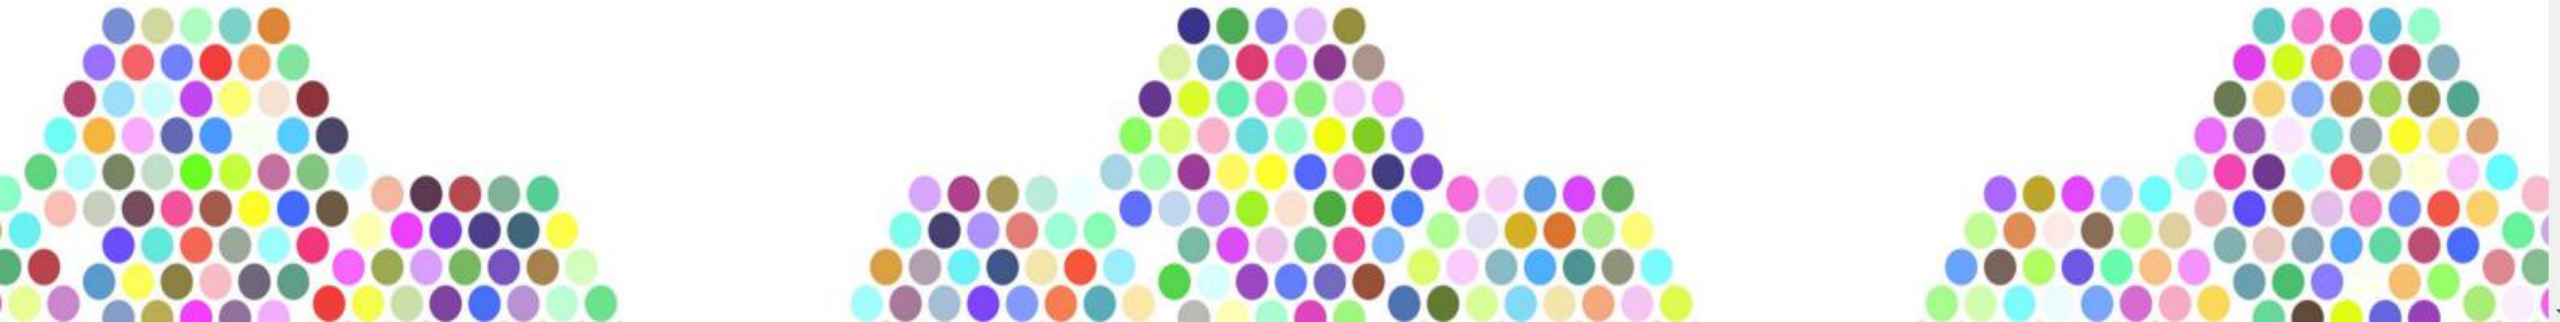

1:preparation:

- environment: Linux Ubuntu 15.04
- tool: python2.7
- 流程：

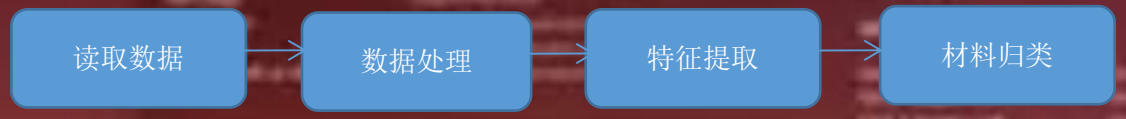

2: begin

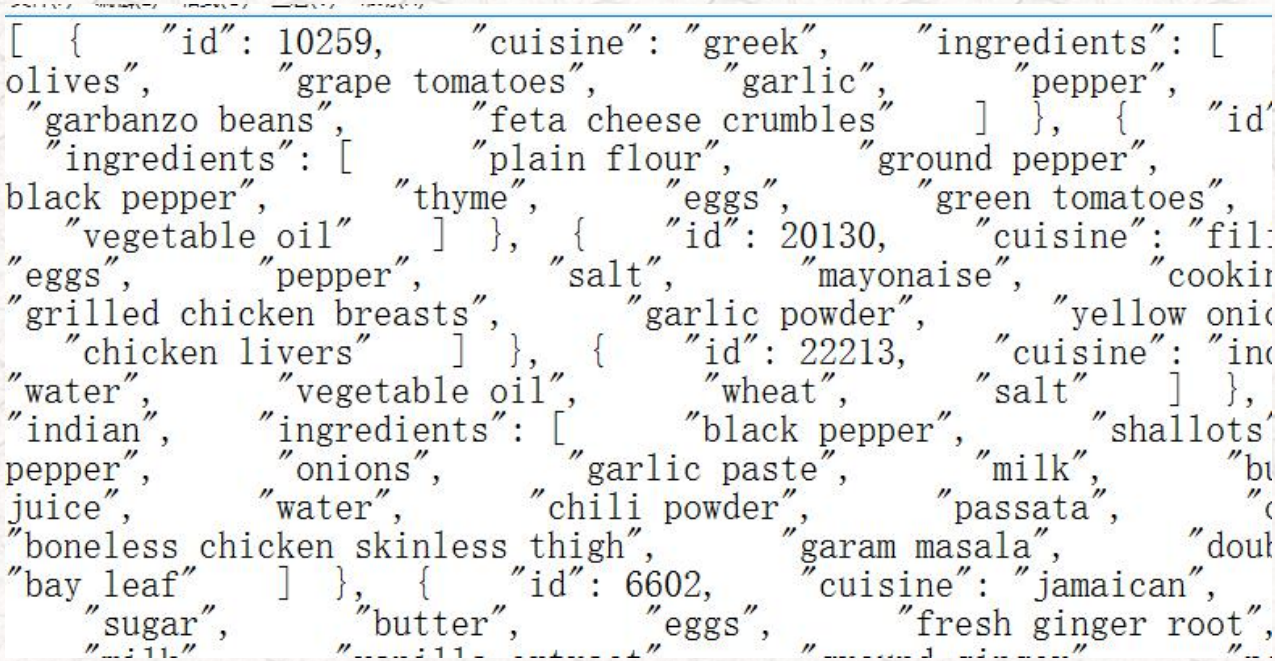

- 我们拿到了两个数据集， test.json 以及 train.json

- 目的： upup.csv

3.deal with the json

- we use "json.load()" to read the json into the python,and get the datas:
- 字符串分离：“hot milk”,"salt"->"hot milk salt" or "hot_milk salt"
- then we use vectorize(掉包) 来进行向量化：
- 其他处理方法：控制train的输入：

4.method ---------begin with logistic

- 对于方法，我一开始掉包使用logistic_regression.
- 结果：77.3；

- 后来自己实现了logistic_regression:
- 结果：73；

5.others method

- 我遇到了起初的瓶颈，与上层建筑差太多。

- 于是，我多样性尝试各种方法
- 正常 grid_search()【一种自动调参数机制】
- random_forest: 69.3
- logistic 77.3 78.8
- linear_SVC: 78.9 79.1
- bys 74.7

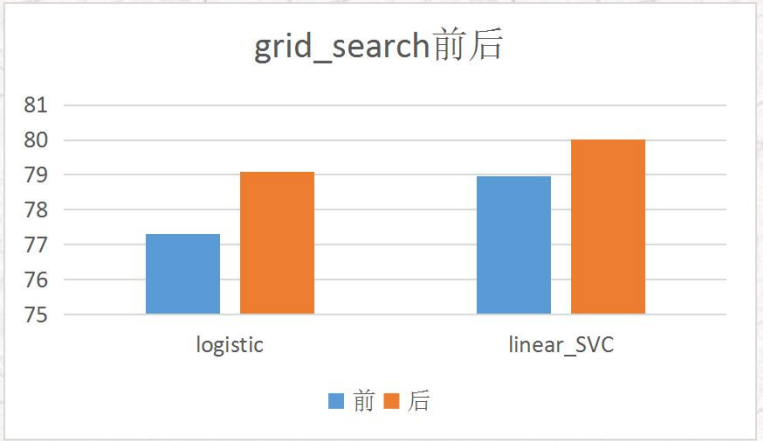

6,then

- 后来，我又尝试了一开始的xgboost：79.0
- 再进行了excel下的vote:
- xgboost+linearSVC+randomforest+bys(myself)　　79.99 better

8,next

- 剔除必要的干扰项
- 进行再优化，而且利用不同方式进行训练，取训练集和测试集中交集作为菜式，进行学习和分类。

- xgboost改良：结合grid_search,先提取ingredient特征，再训练特征模型，之后再将特征模型整合进菜系模型

9，better vote

- 有了更好的子项，我再进行vote。

- 简单的excel函数：

  =IF(B2=C2,B2,A2)

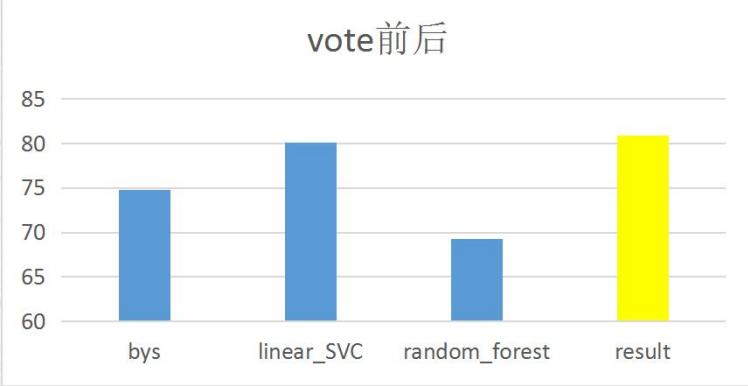

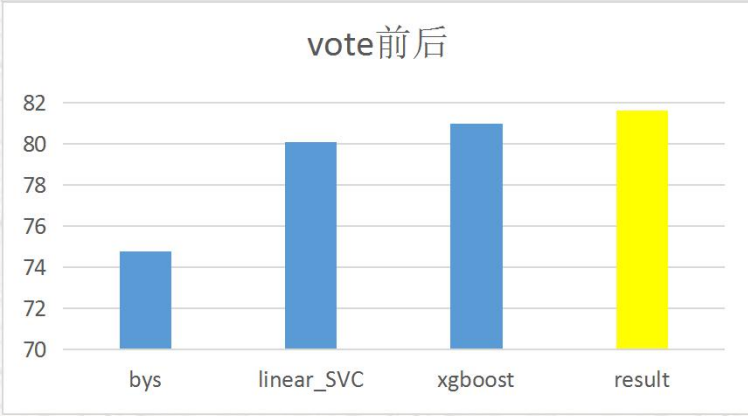

- xgboost+linearSVC+randomForest+bys（myself）：　81.547；

10，final

- 再发现每个国家中有些菜本来就含有国家名。
- 改善程序，有出现国家名直接判定成功。

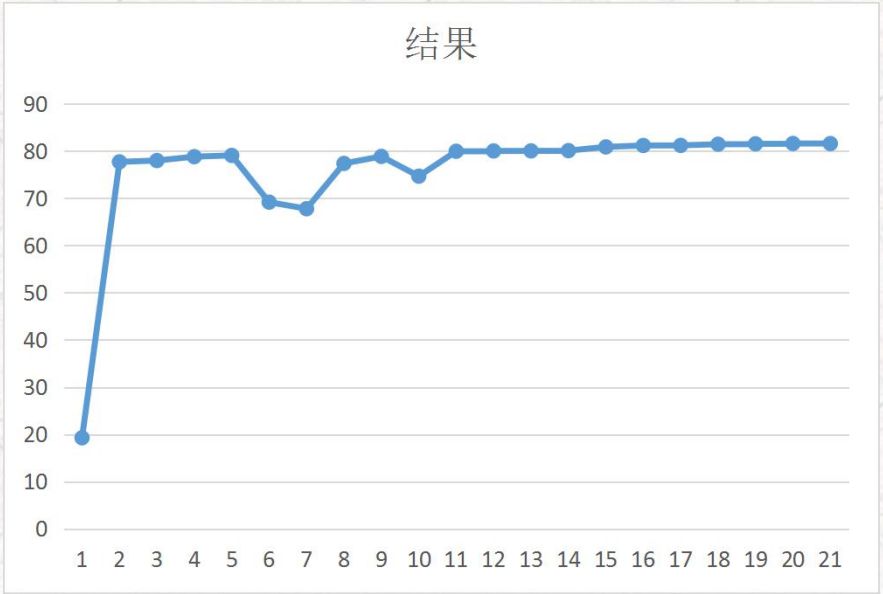

- 结论：我们要持之以恒，不断提升自我。